



ANALÍTICA PARA NEGÓCIOS

GRUPO 37

**PABLO RAFAEL FRANKLIN
ADRIANO DA SILVA SOARES
JOHN DALTON DE PAULA CARIOCA
RODRIGO DE ABREU LIMA
CINTHIA DE SOUSA NASCIMENTO
ANDERSON SILVEIRA TORRES**

**CASE CALIFORNIA HOUSING & INTELIGÊNCIA
OPERACIONAL DE E-COMMERCE**

**FORTALEZA CE
2026**

Analítica para negócios - Case California Housing

1. Introdução

O objetivo deste projeto é aplicar técnicas de **ciência de dados** e **business intelligence** para resolver problemas estratégicos de negócio utilizando o dataset *California Housing*. O foco principal reside em realizar um diagnóstico organizacional baseado nos pilares de *Big Data*, desenvolver modelos preditivos e de clusterização para segmentação de mercado e apresentar os resultados, para essa apresentação foi desenvolvida uma landing page responsiva integrada com PyScript. O projeto transforma dados brutos em inteligência acionável, permitindo a previsão de preços e a identificação de perfis socioeconômicos regionais.

2. Desenvolvimento

Parte 1 – Diagnóstico estratégico de dados

Os 5Vs na base:

- A base apresenta Volume (mais de 20.000 registros);
- Variedade (dados numéricos, geográficos e censitários);
- Velocidade (processamento em tempo real via scripts);
- Veracidade (limpeza de dados e tratamento de outliers);
- Valor (previsões para o mercado imobiliário).

Classificação dos dados: A base é composta por dados estruturados. No contexto imobiliário, dados não estruturados seriam fotos dos imóveis, vídeos de tours virtuais ou descrições textuais de corretores.

Uso estratégico: Essas informações permitem identificar zonas de alta valorização e otimizar investimentos com base no perfil de renda da população.

Parte 2 – Análise exploratória

Importação e Estatística: A base foi importada via **Google Colab** utilizando a biblioteca **pandas**. Calculamos estatísticas descritivas (média, mediana e desvio padrão) que revelaram a amplitude de preços e a concentração de renda em zonas específicas.

Matriz de correlação: Identificamos que a variável "*MedInc*" (renda média) possui a maior correlação positiva com o preço das casas, sendo o fator determinante para a modelagem preditiva.

Parte 3 – Modelagem

PCA (Análise de Componentes Principais): Aplicado para reduzir a complexidade dos dados, mantendo a variância e eliminando redundâncias entre as variáveis censitárias.

K-means: Agrupamos as regiões em clusters socioeconômicos. O cluster de "Alto Padrão" destaca-se por baixa idade dos imóveis e alta renda média.

Regressão linear: O modelo foi treinado para prever preços. O R^2 obtido indicou a precisão do modelo, enquanto os coeficientes mostraram o impacto individual de cada característica (como número de quartos) no valor final.

Parte 4 – Análise de fluxo (cenário e-commerce)

Gargalos de conversão: Identificamos que a maior perda percentual ocorre na transição entre o "Carrinho" e o "Pagamento".

Taxa de conversão: Estabelecida em 10%, servindo como métrica base para otimizações de UX e marketing.

Parte 5 – Mineração de texto

Sentimentos: Através da análise de feedbacks, identificamos um sentimento majoritariamente **positivo**.

Palavras-chave: Termos como "Localização", "Segurança" e "Custo-benefício" foram os mais frequentes, orientando a comunicação publicitária.

Parte 6 – Segmentação e Dashboard

Características dos Clusters:

- **Cluster A:** Regiões litorâneas, alta renda, imóveis valorizados.
- **Cluster B:** Interior, maior densidade populacional, imóveis mais antigos e acessíveis.

KPIs Definidos:

- **Ticket médio regional:** Valor médio dos imóveis por zona.
- **Taxa de conversão:** Eficácia das vendas.
- **Churn rate:** Taxa de abandono de leads.

Esboço do dashboard:

Painel de KPIs Estratégicos

Taxa de Conversão Final

10


Preço Médio Global

\$2.069k


Precisão do Modelo (R^2)

0.606

Funil de Vendas: Identificação de Gargalos



Segmentação de Regiões por Perfil Socioeconômico (K-means)



Parte 7 – Interpretação gerencial

Insights e ações: Recomenda-se focar o marketing em regiões do **Cluster A** e revisar o fluxo de checkout para reduzir a perda de clientes identificada na Parte 4.

Riscos e ética: Um risco relacionado à LGPD é a exposição de coordenadas exatas que possam identificar propriedades privadas. Como viés, identificamos que o modelo pode subestimar valores em áreas rurais devido à menor densidade de dados históricos.

3. Conclusão e Reflexão

Os maiores desafios envolveram a integração técnica do PyScript para execução de Python no navegador e a estruturação de um layout responsivo para dispositivos móveis. Em empresas reais, essa análise permite personalizar a experiência do cliente e reduzir riscos financeiros. O aprendizado principal foi notar que a ciência de dados deve ser comunicada de forma visual e estratégica para que a tomada de decisão seja ágil e baseada em evidências reais.

Links do Projeto

Landing page online:

https://pablo-rafael.github.io/analitica_para_negocios/

Repositório de código:

https://github.com/pablo-rafael/analitica_para_negocios.git

Google Colab (notebook):  `project.ipynb`