



ANALÍTICA PARA NEGÓCIOS

GRUPO 37

**PABLO RAFAEL FRANKLIN
ADRIANO DA SILVA SOARES
JOHN DALTON DE PAULA CARIOCA
RODRIGO DE ABREU LIMA
CINTHIA DE SOUSA NASCIMENTO
ANDERSON SILVEIRA TORRES**

**CASE CALIFORNIA HOUSING & INTELIGÊNCIA
OPERACIONAL DE E-COMMERCE**

**FORTALEZA CE
2026**

Analítica para negócios - Case California Housing

1. Introdução

O objetivo deste projeto é aplicar técnicas de **ciência de dados** e **business intelligence** para resolver problemas estratégicos de negócio utilizando o dataset *California Housing*. O foco principal reside em realizar um diagnóstico organizacional baseado nos pilares de *Big Data*, desenvolver modelos preditivos e de clusterização para segmentação de mercado e apresentar os resultados, para essa apresentação foi desenvolvida uma landing page responsiva integrada com PyScript. O projeto transforma dados brutos em inteligência acionável, permitindo a previsão de preços e a identificação de perfis socioeconômicos regionais.

2. Desenvolvimento

Parte 1 – Diagnóstico estratégico de dados

Os 5Vs na base:

- A base apresenta Volume (mais de 20.000 registros);
- Variedade (dados numéricos, geográficos e censitários);
- Velocidade (processamento em tempo real via scripts);
- Veracidade (limpeza de dados e tratamento de outliers);
- Valor (previsões para o mercado imobiliário).

Classificação dos dados: A base é composta por dados estruturados. No contexto imobiliário, dados não estruturados seriam fotos dos imóveis, vídeos de tours virtuais ou descrições textuais de corretores.

Uso estratégico: Essas informações permitem identificar zonas de alta valorização e otimizar investimentos com base no perfil de renda da população.

Parte 2 – Análise exploratória

Importação e Estatística: A base foi importada via **Google Colab** utilizando a biblioteca pandas. Calculamos estatísticas descritivas (média, mediana e desvio padrão) que revelaram a amplitude de preços e a concentração de renda em zonas específicas.

Matriz de correlação: Identificamos que a variável "*MedInc*" (renda média) possui a maior correlação positiva com o preço das casas, sendo o fator determinante para a modelagem preditiva.

Parte 3 – Modelagem

PCA (Análise de Componentes Principais): Aplicado para reduzir a complexidade dos dados, mantendo a variância e eliminando redundâncias entre as variáveis censitárias.

K-means: Agrupamos as regiões em clusters socioeconômicos. O cluster de "Alto Padrão" destaca-se por baixa idade dos imóveis e alta renda média.

Regressão linear: O modelo foi treinado para prever preços. O R^2 obtido indicou a precisão do modelo, enquanto os coeficientes mostraram o impacto individual de cada característica (como número de quartos) no valor final.

O modelo de regressão linear obteve R^2 de 0,6062, indicando que aproximadamente 61% da variação nos preços dos imóveis é explicada pelas variáveis do modelo. O Erro Quadrático Médio (MSE) foi de 0,5243. Entre os coeficientes, MedInc (renda média) apresentou o maior peso positivo, confirmando ser o principal preditor de valorização, enquanto variáveis geográficas como latitude e longitude também influenciaram significativamente o resultado final.

Parte 4 – Análise de fluxo (cenário e-commerce)

Gargalos de conversão: Identificamos que a maior perda percentual ocorre na transição entre o "Carrinho" e o "Pagamento".

Taxa de conversão: Estabelecida em 10%, servindo como métrica base para otimizações de UX e marketing.

Parte 5 – Mineração de texto

Sentimentos: Através da análise de feedbacks, identificamos um sentimento majoritariamente **positivo**.

Palavras-chave: Termos como "Localização", "Segurança" e "Custo-benefício" foram os mais frequentes, orientando a comunicação publicitária.

Parte 6 – Segmentação e dashboard

Características dos Clusters:

- **Cluster A:** Regiões litorâneas, alta renda, imóveis valorizados.
- **Cluster B:** Interior, maior densidade populacional, imóveis mais antigos e acessíveis.

KPIs Definidos:

- **Ticket médio regional:** Valor médio dos imóveis por zona.
- **Taxa de conversão:** Eficácia das vendas.

- **Churn rate:** Taxa de abandono de leads.

Implementação técnica e bloco de código fonte:

Para a extração de componentes fundamentais, clusterização e predição estatística apresentadas neste relatório, foi desenvolvido um algoritmo robusto em linguagem Python, utilizando bibliotecas de referência em ciência de dados e aprendizado de máquina (*Standard Scaler*, *PCA*, *KMeans* e *Linear Regression*).

Abaixo o fragmento central do código-fonte responsável pelo pipeline de tratamento e modelagem dos dados do ecossistema *California Housing*:

Python

```
import pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.cluster import KMeans
from sklearn.linear_model import LinearRegression

# 1. Normalização de Escala (Z-Score)
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# 2. Redução de Dimensionalidade com PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)

# 3. Clusterização Algorítmica K-Means
kmeans = KMeans(n_clusters=3, random_state=42)
clusters = kmeans.fit_predict(X_scaled)

# 4. Regressão Linear Múltipla para Predição de Valores
model = LinearRegression()
model.fit(X_train, y_train)
```

Detalhamento Técnico das Etapas:

- **StandardScaler:** Aplica a padronização z-score, garantindo que todas as variáveis socioeconômicas e geoespaciais (como renda média e idade dos imóveis) fiquem na mesma escala, impedindo que atributos com números maiores distorçam o algoritmo.
- **PCA (análise de componentes principais):** Reduz a dimensionalidade da base de dados para 2 componentes principais, retendo a maior parte da variância estatística dos dados originais e viabilizando a plotagem bidimensional dos gráficos de dispersão.

- **KMeans**: Algoritmo de aprendizado não supervisionado configurado para agrupar as coordenadas e perfis financeiros em 3 clusters distintos, mapeando com precisão os diferentes segmentos de mercado.
- **LinearRegression**: Modelo supervisionado de regressão linear múltipla treinado para estabelecer a relação entre as variáveis independentes e o valor médio dos imóveis, permitindo projeções preditivas de mercado.

Esboço do dashboard:



Parte 7 – Interpretação gerencial

Insights e ações: Recomenda-se focar o marketing em regiões do **Cluster A** e revisar o fluxo de checkout para reduzir a perda de clientes identificada na Parte 4.

Riscos e ética: Um risco relacionado à LGPD é a exposição de coordenadas exatas que possam identificar propriedades privadas. Como viés, identificamos que o modelo pode subestimar valores em áreas rurais devido à menor densidade de dados históricos.

3. Conclusão e Reflexão

Os maiores desafios envolveram a integração técnica do PyScript para execução de Python no navegador e a estruturação de um layout responsivo para dispositivos móveis. Em empresas reais, essa análise permite personalizar a experiência do cliente e reduzir riscos financeiros. O aprendizado principal foi notar que a ciência de dados deve ser comunicada de forma visual e estratégica para que a tomada de decisão seja ágil e baseada em evidências reais.

Links do Projeto

Landing page online:

https://pablo-rafael.github.io/analitica_para_negocios/

Repositório de código:

https://github.com/pablo-rafael/analitica_para_negocios.git

Google Colab (notebook):  `project.ipynb`